

AutoLens AI: Görüntü İşleme ve Derin Öğrenme ile Araba Gövde Tipi Sınıflandırma

*Kocaeli Üniversitesi Yazılım Laboratuvarı-II Proje 3

Enes Demir
Bilgisayar Mühendisliği
Kocaeli Üniversitesi
Kocaeli, Türkiye
230202066@kocaeli.edu.tr

Özet—Sekiz farklı araba gövde tipini sınıflandırmak için AutoLens AI adlı derin öğrenme sistemi geliştirilmiştir. Sınıflar arası ciddi veri dengesizliği (Micro 22, SUV 670 örnek) Weighted Cross-Entropy Loss ile aşılmış; CNN ve Vision Transformer mimarileri sistematik olarak karşılaştırılmıştır. En yüksek başarımlı, öz-denetimli öğrenme ile ön eğitilmiş DINOv3 ViT-S/16 modelinin güvenli veri artırımı ve Dirichlet kalibrasyonu ile birleştirilmesiyle elde edilmiştir. Nihai model, 3170 örnekle iç test setinde %95.84 doğruluk, 0.9507 Makro F1 ve %0.97 Expected Calibration Error (ECE) değerlerine ulaşmıştır. Olasılık kalibrasyonunda Dirichlet yöntemi Temperature Scaling ve Vector Scaling'i Val NLL (0.1371), ECE (%0.96) ve Test F1 (0.9537) metriklerinde geride bırakmıştır. Model 95 MB sınırının altında (82.6 MB ONNX) optimize edilmiş ve Gradio tabanlı web arayüzü ile sunulmuştur.

Index Terms—Derin Öğrenme, Görüntü Sınıflandırma, Vision Transformer, DINOv3, Kalibrasyon, Araba Gövde Tipi.

I. GİRİŞ

Günümüzde otonom sistemler, trafik yönetimi ve güvenlik alanlarında araçların fiziksel özelliklerinin doğru ve hızlı tespiti büyük önem taşımaktadır. Bu çalışma kapsamında, sekiz farklı araç gövde tipini (SUV, VAN, Station Wagon, Micro, Açık Tekerlekli/F1, Sedan, Hatchback, Pick-up) sınıflandıran bir derin öğrenme modeli geliştirilmiştir.

Katkılarımız dört ana başlıkta özetlenebilir:

- 1) **Sistematik model karşılaştırması:** Dört farklı mimari (ResNet18, EfficientNet-B2, MobileNetV4, DINOv3 ViT-S/16) aynı veri bölütlemesi ve değerlendirme protokolü altında karşılaştırılmış, LoRA ve tam ince ayar varyantları ayrı ayrı test edilmiştir. DINOv3'ün Makro F1'de CNN'lere +0.0205 ila +0.0677 puan üstünlük sağladığı gösterilmiştir.
- 2) **Veri dengesizliği stratejisi:** Focal Loss ($\gamma = 2.0$) ve Weighted Cross-Entropy Loss (maksimum ağırlık 5.0), DINOv3 üzerinde ablasyon çalışmalarıyla karşılaştırılmış; Weighted CE'nin Makro F1'de +0.0205, azınlık sınıflarında ise +0.065'e varan üstünlük sağladığı deneysel olarak kanıtlanmıştır.
- 3) **Güvenli veri artırımı (safe augmentation):** Aracın silüetini koruyan, agresif geometrik dönüşümlerden kaçınan bir artırım politikası uygulanmış ve EMA (Ex-

ponential Moving Average) ile birleştirildiğinde Makro F1'de +0.0320 puanlık iyileşme sağlanmıştır.

- 4) **Kapsamlı olasılık kalibrasyonu:** Temperature Scaling, Vector Scaling ve Dirichlet (ODIR) yöntemleri grid search ile karşılaştırılmış; Dirichlet kalibrasyonu ile ECE %10.33'ten %0.96'ya düşürülerek modelin aşırı güven (overconfidence) sorunu giderilmiştir. Ayrıca farklı modellerin (EfficientNet-B2, DINOv3 baseline) kalibrasyon ihtiyaçları analiz edilmiştir.

Veri seti açık kaynaklardan toplanmış, sınıflar arası dengesizlik sınıf ağırlıklı hata fonksiyonları ile ele alınmıştır. Proje teslim gereksinimleri doğrultusunda model 95 MB altında ONNX formatında paketlenmiş ve canlı demo web arayüzü ile sunulmuştur.

II. İLGİLİ ÇALIŞMALAR

Araç sınıflandırma sistemleri üzerine literatürde birçok çalışma bulunmaktadır. Geleneksel yöntemler HOG (Histogram of Oriented Gradients) gibi el yapımı özniteliklere dayanırken, son yıllarda CNN'ler bu alanda baskın hale gelmiştir. ResNet ve EfficientNet gibi mimariler görüntü sınıflandırmada yüksek başarı elde etmiştir [1], [2].

Transformer mimarisinin görüntü işlemeye uyarlanmasıyla ortaya çıkan Vision Transformer (ViT) modelleri, uzun mesafeli bağımlılıkları yakalama kapasiteleri sayesinde CNN'lere güçlü bir alternatif oluşturmuştur [3]. Öz-denetimli öğrenme yaklaşımını kullanan DINO serisi [4], [5], ImageNet'te etiket kullanmadan güçlü görsel temsiller öğrenmekte ve transfer öğrenmede CNN tabanlı yöntemlere üstünlük sağlamaktadır. Olasılık kalibrasyonunda ise Dirichlet (ODIR) kalibrasyonu, çok sınıflı problemlerde Temperature Scaling'in tek parametreliliğine kıyasla her sınıf için ayrı bir beta dağılımı parametrelerindirek daha esnek bir düzeltme sunmaktadır [6].

III. SİSTEM MIMARISI VE METODOLOJİ

A. Veri Seti ve Ön İşleme

Sınıflandırma için SUV, VAN, Station Wagon, Micro, Açık Tekerlekli (F1), Sedan, Hatchback ve Pick Up olmak üzere 8 sınıf belirlenmiştir. Toplam 31,612 görüntü açık kaynaklardan

Tablo I
TEST SETİ SINIF DAĞILIMLARI (3170 ÖRNEK)

Sınıf	Örnek Sayısı	Oran (%)
Sedan	836	26.4
SUV	670	21.1
Açık Tekerlekli (F1)	586	18.5
VAN	455	14.4
Pick Up	269	8.5
Hatchback	266	8.4
Station Wagon	66	2.1
Micro	22	0.7

toplanmış, etiketlenmiş ve iki aşamalı tabakalı (stratified) rastgele bölme ile ayrılmıştır:

$$S_{\text{eligible}} \xrightarrow[80\%]{\text{stratify}} S_{\text{train}}, \quad S_{\text{remain}} \xrightarrow[50\%]{\text{stratify}} S_{\text{val}} + S_{\text{test}} \quad (1)$$

sklearn train_test_split fonksiyonu random_state=42 ile iki kez çağırılmıştır: ilk bölmede %80 eğitim (25,285), ardından kalan %20 üzerinde %50 doğrulama (3,157) ve %50 iç test (3,170) ayrılmıştır ([7]). Tabakalı bölme sayesinde her sınıfın eğitim/doğrulama/test setlerindeki oranı korunmuştur (Tablo II).

Tablo II
SINIFLARIN EĞİTİM/DOĞRULAMA/İÇ TEST DAĞILIMI

Sınıf	Eğitim	Doğrulama	İç Test
Sedan	6,680	835	836
SUV	5,351	668	670
F1	4,676	584	586
VAN	3,631	453	455
Hatchback	2,120	265	266
Pick Up	2,143	267	269
St. Wagon	520	65	66
Micro	164	20	22
Toplam	25,285	3,157	3,170

Sınıf dağılımları doğal olarak dengesizdir: en büyük sınıf Sedan (836 test örneği) ile en küçük sınıf Micro (22 test örneği) arasında yaklaşık 38 kat fark bulunmaktadır. Görüntüler 256×256 boyutunda yeniden boyutlandırılıp merkez kırpmaya uygulanmıştır.

Veri artırımı (data augmentation) politikası dikkatle tasarlanmıştır. Amacımız, modelin genelleme kapasitesini artırırken aracın ayırt edici silüet özelliklerini korumaktır. Bu nedenle “güvenli” bir artırım politikası benimsenmiştir. Augmentasyon pipeline’ı sırasıyla şu dönüşümlerden oluşmaktadır: (1) rastgele yatay çevirme (probability=0.5), (2) hafif perspektif dönüşümü (distortion_scale=0.1), (3) renk dönüşümleri: parlaklık ayarı $\pm 20\%$, kontrast ayarı $\pm 10\%$, doygunluk ayarı $\pm 10\%$ ve hue kaydırma $\pm 5\%$, (4) Gauss bulanıklaştırma (kernel=3, sigma=(0.1, 1.0)) ve (5) CLAHE eşitleme (clip_limit=2.0, grid=(8,8)). Hatchback-Sedan ayrımını bozacak agresif kırpmaya, döndürme veya esnetmeden kaçınılmıştır.

Bu politika, modelin gerçek dünya varyasyonlarına karşı dayanıklılığını artırırken sınıflar arası ayrımı zorlaştıracak artefaktlardan kaçınmayı hedeflemektedir.

B. Model Mimarisi ve Karşılaştırması

1) *CNN Modelleri*: İlk aşamada üç CNN mimarisi ImageNet ön eğitimi ile test edilmiştir:

ResNet18 (11.2M parametre): Artık bağlantıları (residual connections) sayesinde 18 katmanlı derin ağ eğitimi kolaylaştıran temel CNN mimarisidir. 512 boyutlu öznetelik vektörü ile sınıflandırma katmanına bağlanmıştır. Düşük parametre sayısı sayesinde hızlı eğitim ve çıkarım avantajı sunmaktadır.

EfficientNet-B2 (9.0M parametre): Compound scaling prensibi ile derinlik, genişlik ve çözünürlüğü birlikte optimize eden verimli bir mimaridir. B2 varyantı, 140×140 taban çözünürlük ve 1.1 derinlik katsayısı ile dengeli bir performans sunmaktadır. B0’a kıyasla daha yüksek kapasiteye sahiptir.

MobileNetV4-Conv-M (9.0M parametre): 2024 yılında yayımlanan, mobil cihazlarda çıkarım için tasarlanmış güncel bir CNN modelidir. Universal Inverted Bottleneck (UIB) bloğu ile hem konvansiyonel hem de mobil-optimize edilmiş operasyonları birleştirmektedir.

Tüm CNN’ler PyTorch Lightning ile 30 epoch eğitilmiş, öğrenme oranı 0.001 ve batch size 128 kullanılmıştır. Erken durdurma ve model kaydetme işlemleri doğrulama F1 skoruna göre yapılmıştır.

2) *Vision Transformer*: **DINOv3**: CNN’lerin ardından Vision Transformer tabanlı **DINOv3 ViT-S/16** (21.6M parametre) değerlendirilmiştir. DINOv3, Meta AI tarafından geliştirilen üçüncü nesil DINO serisi olup ImageNet-1K üzerinde öz-denetimli öğrenme (self-supervised learning) ile ön eğitilmiştir. ViT-S/16 varyantı, 16×16 piksel boyutunda görüntü parçacıkları (patch) kullanan 21.6M parametrelili küçük bir Vision Transformer’dır. Öz-denetimli eğitim sayesinde etiketli veriye ihtiyaç duymadan güçlü görsel temsiller öğrenmekte ve transfer öğrenmede yüksek başarımlar sağlamaktadır.

İki ince ayar stratejisi test edilmiştir: (1) **Tam ince ayar** – tüm model ağırlıkları güncellenmiş, yeni sınıflara tam uyum sağlanmıştır. (2) **LoRA** (Low-Rank Adaptation, $r=8$, $\alpha=16$) – yalnızca 0.3M parametre eklenerek düşük ranklı adaptasyon denenmiştir. LoRA, büyük modellerde parametre verimli ince ayar için popüler bir yöntem olmasına rağmen, bu çalışmada beklentiyi karşılamamıştır.

Tablo III
ADAY MODELLERİN MIMARI KARŞILAŞTIRMASI

Model	Parametre	Giriş	ONNX
DINOv3 ViT-S/16	21.6M	256^2	82.6 MB
ResNet18	11.2M	224^2	42.6 MB
EfficientNet-B2	9.0M	224^2	29.4 MB
MobileNetV4	9.0M	224^2	32.1 MB

Tablo IV incelendiğinde, DINOv3 tam ince ayar varyantı tüm metriklerde CNN tabanlı modelleri geride bırakmıştır. EfficientNet-B2, CNN’ler arasında en başarılı model olurken

Tablo IV
TÜM MODEL ADAYLARININ İÇ TEST SETİ KARŞILAŞTIRMASI (3170 ÖRNEK)

Model	Doğruluk ↑	Macro F1 ↑	Weighted F1 ↑
DINOv3 (Tam)	0.9438	0.9187	0.9442
EfficientNet-B2	0.9202	0.8982	0.9201
ResNet18	0.8968	0.8590	0.8963
MobileNetV4	0.8905	0.8510	0.8912
DINOv3 (LoRA)	0.7820	0.6316	–

(0.8982 Macro F1), MobileNetV4 en düşük performansı göstermiştir (0.8510). DINOv3'ün LoRA varyantı 0.6316 Macro F1 ile beklentinin altında kalmış ve elenmiştir. DINOv3'ün öz-denetimli ön eğitimi sayesinde sınırlı veri ile yüksek genelleme sağladığı, özellikle Macro Recall'de (0.9121) CNN'lere belirgin üstünlük kurduğu gözlemlenmiştir.

DINOv3'ün CNN'lere üstünlüğünün temel nedeni, öz-denetimli (self-supervised) ön eğitim sırasında ImageNet üzerinde etiket kullanmadan öğrenilen zengin görsel temsillerdir. ViT mimarisi, global attention mekanizması sayesinde bir aracın tüm gövde yapısını bütüncül olarak değerlendirebilmekte, CNN'lerin yerel reseptif alan sınırlamasını aşmaktadır. EfficientNet-B2'nin CNN'ler arasında öne çıkması, compound scaling stratejisinin dengeli bir öznetelik çıkarıcı sağlamasıyla açıklanabilir. LoRA'nın başarısızlığı ise düşük ranklı adaptasyonun ($r=8$) DINOv3 gibi öz-denetimli bir modelin temsil uzayını yeni sınıflara yeterince uyarlayamamasından kaynaklanmaktadır: yalnızca 0.3M parametre (toplamın %1.4'ü) güncellenmiş, bu da görev odaklı ince ayar için yetersiz kalmıştır.

C. Eğitim Süreci ve Hiperparametre Seçimi

Nihai model mimarisi DINOv3 olarak belirlendikten sonra eğitim hiperparametreleri deneysel olarak optimize edilmiştir. AdamW optimizörü, $\beta_1 = 0.9$, $\beta_2 = 0.999$ varsayılan parametreleriyle kullanılmış; öğrenme oranı 0.0001, weight decay 0.0001 olarak ayarlanmıştır. Öğrenme oranı seçiminde, Vision Transformer modelleri için önerilen düşük öğrenme oranı stratejisi izlenmiş; Cosinus Annealing yerine sabit öğrenme oranı tercih edilmiştir.

Label smoothing ($\varepsilon = 0.05$) kaybı aşağıdaki gibi düzenlenmektedir:

$$\mathcal{L}_{LS} = -(1 - \varepsilon) \log(p_y) - \frac{\varepsilon}{K} \sum_{k=1}^K \log(p_k) \quad (2)$$

Burada $K = 8$ sınıf sayısı, p_y doğru sınıf olasılığıdır. Label smoothing, modelin aşırı güvenli tahminler yapmasını engelleyerek genelleme kapasitesini artırmakta ve kalibrasyonu iyileştirmektedir. Ön denemelerde $\varepsilon = 0.1$ ile kalibrasyon sonrası ECE'de %0.2 mutlak iyileşme gözlemlenmiş ancak F1'de hafif düşüş yaşanmış; $\varepsilon = 0.05$ denge noktası olarak seçilmiştir.

Drop path rate (0.1) ve weight decay (0.0001) ek düzenleme sağlamaktadır. EMA (Exponential Moving Average, decay=0.999) ile her adımda model ağırlıklarının yumuşatılmış ortalaması alınmış, $\theta_{EMA} \leftarrow 0.999 \cdot \theta_{EMA} + 0.001 \cdot \theta$ şeklinde

güncellenmiştir. Gradient clipping (max norm=1.0) ile gradyan patlaması önlenmiştir. Erken durdurma (patience=12, monitor=val/f1_macro, mode=max) ile 42 epoch sonunda eğitim durdurulmuş, en iyi ağırlıklar 29. epoch'ta kaydedilmiştir. Batch size 128 ve BF16 karma hassasiyet (mixed precision) ile 26.9M parametrelili model M2 Pro üzerinde yaklaşık 45 dakikada eğitilmiştir.

D. Ablasyon Çalışmaları

1) *Kayıp Fonksiyonu: Focal vs Weighted CE*: Sınıf dengesizliğini ele almak için iki kayıp fonksiyonu DINOv3 üzerinde karşılaştırılmıştır. Weighted Cross-Entropy, her örnek için sınıf frekansının tersiyle ağırlıklandırma yaparken (maksimum ağırlık 5.0 ile sınırlı), Focal Loss ($\gamma = 2.0$) kolay örneklerin katkısını azaltarak zor örneklerle odaklanmaktadır. Matematiksel olarak:

$$\mathcal{L}_{WCE} = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \log(p_{i,y_i}), \quad w_c = \min\left(\frac{N}{K \cdot n_c}, 5.0\right) \quad (3)$$

$$\mathcal{L}_{Focal} = -\frac{1}{N} \sum_{i=1}^N (1 - p_{i,y_i})^\gamma \log(p_{i,y_i}) \quad (4)$$

Burada N toplam örnek, $K = 8$ sınıf, n_c sınıf c 'nin frekansı, p_{i,y_i} i örneğinin doğru sınıf olasılığıdır. Her iki model aynı veri artırımı ve EMA politikası ile eğitilmiştir. Weighted CE'de ağırlık tavanı (clipping) 5.0 ile sınırlanarak aşırı ağırlıklandırmanın gürültü amplifikasyonu engellenmiştir.

Tablo V
KAYIP FONKSİYONU ABLASYONU – GENEL METRİKLER (DINOv3 + SAFE AUG + EMA)

Metric	Weighted CE	Focal Loss	Fark
Accuracy ↑	0.9584	0.9505	+0.0079
Macro F1 ↑	0.9507	0.9302	+0.0205
Weighted F1 ↑	0.9584	0.9502	+0.0082
Macro Precision ↑	0.9561	0.9358	+0.0203
Macro Recall ↑	0.9456	0.9269	+0.0187

Weighted CE, tüm metriklerde Focal Loss'a üstünlük sağlamıştır. En büyük fark Makro F1'de (+0.0205) görülmüştür. Focal Loss'un iyi öğrenilmiş sınıflardaki kaybı sıfıra yaklaştırma özelliği, dengeli sınıflarda avantaj sağlasa da azınlık sınıflarındaki zayıf performansı genel başarıyı düşürmüştür.

Tablo VI sınıf bazlı detay incelendiğinde, Weighted CE'nin özellikle azınlık sınıflarında (Micro +0.0465, Station Wagon +0.0650, Pick Up +0.0244) belirgin iyileşme sağladığı görülmektedir. Bol örnekli sınıflarda (Sedan, VAN, F1) iki yöntem arasındaki fark ihmal edilebilir düzeydedir. Bu sonuç, ağırlıklandırma stratejisinin dengesiz veri setlerinde Focal Loss'a kıyasla daha etkili olduğunu göstermektedir. Sınıf bazlı F1 değerleri, her iki modelin export dizinindeki per_class_metrics.txt dosyasından alınmıştır.

Tablo VI
SINIF BAZLI F1 KARŞILAŞTIRMASI: WEIGHTED CE VS FOCAL LOSS

Sınıf	Weighted CE F1 ↑	Focal Loss F1 ↑	Fark
SUV	0.9504	0.9372	+0.0132
VAN	0.9856	0.9832	+0.0024
Station Wagon	0.9302	0.8652	+0.0650
Micro	0.9767	0.9302	+0.0465
F1	0.9991	0.9966	+0.0025
Sedan	0.9591	0.9589	+0.0002
Hatchback	0.8731	0.8628	+0.0103
Pick Up	0.9314	0.9070	+0.0244

Tablo VII
VERİ ARTIRIMI ABLASYONU (DINOv3 + WEIGHTED CE)

Konfigürasyon	Accuracy ↑	Macro F1 ↑	Weighted F1 ↑
Augmentasyonsuz (Baseline)	0.9438	0.9187	0.9442
Safe Aug + EMA	0.9584	0.9507	0.9584

2) *Veri Artırımı Etkisi:* Veri artırımının katkısını ölçmek için augmentasyonsuz DINOv3 (Baseline) ile safe augmentation + EMA kullanılan versiyon karşılaştırılmıştır:

Safe augmentation ve EMA eklenmesi tüm metriklerde iyileşme sağlamış, Makro F1’de +0.0320 puanlık bir artış elde edilmiştir. Bu iyileşmenin büyük kısmı, veri artırımının özellikle az örnekli sınıflardaki genelleme kapasitesini artırmasından kaynaklanmaktadır.

E. Olasılık Kalibrasyonu

1) *Kalibrasyon Problemi ve Yöntemler:* Derin öğrenme modelleri genellikle aşırı güven (overconfidence) eğilimindedir: bir görüntüyü %90 olasılıkla sınıflandırdıklarında, gerçek doğruluk oranı %90’ın altında olabilir. Bu çalışmada üç kalibrasyon yöntemi karşılaştırılmıştır:

Temperature Scaling: Softmax çıktılarına tek bir sıcaklık parametresi (T) uygulayarak olasılıkları yumuşatır: $\hat{p}_k = \sigma_{SM}(\mathbf{z}/T)_k$. Tek parametrelili olduğu için en basit yöntemdir ancak her sınıf için aynı düzeltmeyi uygular. $T = 1.0$ kalibrasyonsuz duruma, $T > 1$ daha düz (uniform) olasılıklara, $T < 1$ daha keskin olasılıklara karşılık gelir.

Vector Scaling: Her sınıf için ayrı bir ağırlık vektörü ($\mathbf{w}$) ve bias (b) öğrenir: $\hat{p}_k = \sigma_{SM}(\mathbf{w} \odot \mathbf{z} + b)_k$. Temperature Scaling’den daha esnektir ancak aşırı öğrenmeye yatkındır; bu nedenle L2 düzenleme (λ) ile birlikte kullanılır.

Dirichlet (ODIR) Kalibrasyonu: Her sınıf için ayrı bir beta dağılımı parametrelendirilerek sınıf bazlı olasılık düzeltmesi yapar ([6]). ODIR (Ordered Dirichlet) versiyonu, sınıf sıralamasını koruyarak daha kararlı kalibrasyon sağlar.

2) *DINOv3 Weighted Kalibrasyon Sonuçları:* DINOv3 Weighted modeli üzerinde tüm yöntemler grid search ile optimize edilmiştir. Dirichlet ve Vector Scaling için $\lambda \in \{0.001, 0.01, 0.1, 1.0\}$ değerleri taranmıştır.

Dirichlet kalibrasyonu tüm metriklerde en başarılı yöntem olmuştur. ECE (Expected Calibration Error), sınıflandırıcının güven-doğruluk tutarlılığını ölçmektedir. M adet eşit genişlikli güven aralığına bölünen $[0, 1]$ aralığında:

Tablo VIII
KALIBRASYON YÖNTEMLERİ KARŞILAŞTIRMASI (DINOv3 WEIGHTED)

Yöntem	Val NLL ↓	ECE ↓	Test F1
Kalibrasyonsuz	0.2585	0.1033	–
Temperature Scaling	0.2045	0.0211	0.9496
Vector Scaling ($\lambda = 0.01$)	0.1706	0.0232	0.9450
Dirichlet ($\lambda = 0.001$)	0.1371	0.0096	0.9537

Tablo IX
İÇ TEST SETİ KALIBRASYON METRİKLERİ (DINOv3 WEIGHTED)

Metrik	Öncesi	Temp.	Vector	Dirichlet
ECE ↓	0.0984	0.0156	0.0214	0.0097
NLL ↓	0.2644	0.2136	0.1806	0.1487
CW-ECE ↓	0.0292	0.0119	–	0.0045

$$ECE = \sum_{m=1}^M \frac{|B_m|}{N} \left| \frac{1}{|B_m|} \sum_{i \in B_m} \mathbb{I}(\hat{y}_i = y_i) - \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i \right| \quad (5)$$

Burada B_m m aralığındaki örnekler, $\hat{y}_i$ tahmin, y_i gerçek etiket, $\hat{p}_i$ tahmin olasılığıdır. ECE %10.33’ten %0.97’ye düşürülerek modelin aşırı güven problemi büyük ölçüde giderilmiştir. Class-wise ECE (CW-ECE) değerinin 0.0045’e inmesi, düzeltmenin tüm sınıflarda tutarlı olduğunu göstermektedir.

Tablo X
DIRICHLET KALIBRASYONU DÜZENLİLEŞTİRME TARAMASI (λ): DOĞRULAMA SETİ METRİKLERİ

λ	Val NLL ↓	Val ECE ↓	Test F1 ↑
0.001	0.1371	%0.96	0.9537
0.01	0.1416	%1.01	0.9515
0.1	0.1483	%1.10	0.9511
1.0	0.1571	%1.23	0.9438

Tablo X’de Dirichlet kalibrasyonunun λ düzenleme parametresine duyarlılığı gösterilmektedir. En düşük λ değeri (0.001) en iyi kalibrasyon sonucunu verirken, λ arttıkça ECE düzenli olarak yükselmekte ve Test F1 düşmektedir. $\lambda = 1.0$ ’da Test F1 0.9438’e gerilemekte, bu da aşırı düzenlemenin sınıflandırma başarımını olumsuz etkilediğini göstermektedir.

3) *Farklı Modellerde Kalibrasyon Analizi:* Kalibrasyon ihtiyacı model mimarisine ve kullanılan kayıp fonksiyonuna göre değişiklik göstermektedir. DINOv3’ün üç varyantı (baseline, Weighted CE, Focal Loss) ile EfficientNet-B2 modelinin kalibrasyon öncesi ve sonrası durumları karşılaştırılmıştır.

Tablo XI ilginç bir bulguyu ortaya koymaktadır: Weighted CE ile eğitilen model, kalibrasyon öncesi en yüksek ECE değerine (%9.84) sahip olmasına rağmen, Dirichlet kalibrasyonu sonrası en düşük ECE’ye (%0.97) ulaşmıştır. Bu, ağırlıklandırmanın olasılık dağılımını bozduğunu (aşırı güven yarattığını) ancak Dirichlet kalibrasyonunun bu bozulmayı etkili bir şekilde düzelttiğini göstermektedir. Buna karşılık, Focal Loss modeli daha düşük başlangıç ECE’sine (%7.64)

Tablo XI
FARKLI MODELLERDE KALIBRASYON ÖNCESİ ECE VE DIRICHLET SONRASI İYİLEŞME

Model	Öncesi ECE ↓	Sonrası ECE ↓	Düşüş
DINOV3 Weighted	0.0984	0.0097	%90.1
DINOV3 Focal	0.0764	0.0184	%75.9
DINOV3 Baseline	0.0396	0.0104	%73.7
EfficientNet-B2	0.0382	0.0104	%72.8

sahip olmasına rağmen kalibrasyon sonrası daha yüksek ECE (%1.84) ile kalmıştır.

CNN tabanlı EfficientNet-B2 ve DINOV3 baseline modelleri, kalibrasyon öncesi düşük ECE değerleriyle (%)3.8-4.0 zaten nispeten iyi kalibre durumdadır. Bu modellerde Dirichlet kalibrasyonu sonrası ECE %1.04'e düşmekle birlikte, iyileşme oranı DINOV3 Weighted modeline kıyasla daha sınırlıdır (%)73'e karşı %90). Bu durum, ağır mimarilerin (özellikle ağırlıklandırma gibi post-hoc düzenlemelerle) daha güçlü kalibrasyon yöntemlerine ihtiyaç duyduğunu göstermektedir.

Dirichlet yönteminin bir diğer avantajı, kalibrasyon sonrası F1 skorunu da iyileştirmesidir. Temperature Scaling (0.9496) ve Vector Scaling'e (0.9450) kıyasla Dirichlet kalibrasyonu sonrası Test F1 değeri 0.9537'ye yükselmiştir. Bu iyileşme, daha iyi kalibre edilmiş olasılıkların sınıflandırma karar sınırlarını da olumlu etkilediğini göstermektedir. Tablo X'de görüldüğü gibi, $\lambda = 0.001$ 'den $\lambda = 1.0$ 'a çıkıldıkça ECE %0.96'dan %1.23'e yükselmekte, bu da aşırı düzenleştirmenin kalibrasyon kalitesini düşürdüğünü göstermektedir.

IV. DEĞERLENDİRME VE SONUÇLAR

A. Nihai Model Performansı

Nihai model (DINOV3 + Safe Aug + Weighted CE + Dirichlet) 3170 örnekli iç test setinde aşağıdaki başarıyı elde etmiştir: %95.84 doğruluk, 0.9507 Makro F1, 0.9584 Weighted F1, 0.9561 Makro Precision, 0.9456 Makro Recall. Bu değerler, projenin tüm performans hedeflerini karşılamaktadır.

Tablo XII
NİHAİ MODEL SINIF BAZLI PERFORMANS METRİKLERİ (İÇ TEST)

Sınıf	Precision ↑	Recall ↑	F1 ↑	Örnek
SUV	0.9576	0.9433	0.9504	670
VAN	0.9933	0.9780	0.9856	455
Station Wagon	0.9524	0.9091	0.9302	66
Micro	1.0000	0.9545	0.9767	22
F1	1.0000	0.9983	0.9991	586
Sedan	0.9496	0.9689	0.9591	836
Hatchback	0.8667	0.8797	0.8731	266
Pick Up	0.9296	0.9331	0.9314	269


En yüksek başarımlı F1 araçları sınıfında (0.9991 F1), en düşük başarımlı ise Hatchback sınıfında (0.8731 F1) elde edilmiştir. Hatchback'in Sedan'a olan yapısal benzerliği (kısa bagaj, eğimli tavan) bu sınıftaki hataların ana kaynağıdır. Micro sınıfında yalnızca 22 test örneği olmasına rağmen 0.9767 F1 değeri, ağırlıklandırma stratejisinin azınlık sınıflarındaki başarısını kanıtlamaktadır. Precision, Recall ve F1

değerleri sklearn.metrics.classification_report çıktısından alınarak per_class_metrics.txt dosyasına kaydedilmiştir.


B. Eğitim Süreci ve Karışıklık Matrisi

Eğitim ve doğrulama kayıpları birbirine yakın seyretmiş, aşırı öğrenme belirtisi gözlemlenmemiştir. Model, ilk 5 epoch'ta hızla %84 doğrulamaya ulaşmış, 10. epoch'tan itibaren %93'ün üzerine çıkmış ve 29. epoch'ta en yüksek doğrulama F1'ine (0.9491) erişmiştir. Eğitimin erken aşamalarında (1.-5. epoch) kaybın hızla düşmesi, DINOV3'ün ImageNet ön eğitiminin sağladığı güçlü başlangıç temsillerinin bir göstergesidir.

Doğrulama kaybının eğitim kaybına paralel seyretmesi, modelin aşırı öğrenmeye girmedikçe göstermektedir. 12. epoch'tan itibaren doğrulama kaybı 0.12-0.15 aralığında sabitlenmiş, bu da modelin kapasite sınırına ulaştığına işaret etmektedir. Erken durdurma (patience=12) sayesinde gereksiz eğitim döngülerinden kaçınılmış ve en iyi ağırlıklar 29. epoch'ta kaydedilmiştir. 42 epoch sonunda eğitim durdurulduğunda doğrulama kaybında belirgin bir artış gözlemlenmemiştir.




Şekil 1. Epochlara göre eğitim ve doğrulama kaybı (Loss) grafiği. Epoch başına train/val loss değerleri metrics.csv dosyasından alınmış, pandas + matplotlib ile çizilmiştir.




Şekil 2. Epochlara göre eğitim ve doğrulama doğruluğu (Accuracy) grafiği. Değerler metrics.csv içindeki train/val accuracy sütunlarından okunmuştur.

Şekil 4'de modelin her sınıf için sklearn.metrics.roc_auc_score ile multi_class="ovr" parametresi kullanılarak hesaplanan One-vs-Rest ROC eğrileri



Şekil 3. Normalize edilmiş karışıklık matrisi (8×8). sklearn.metrics.confusion_matrix ile normalize edilmiş, seaborn heatmap ile görselleştirilmiş ve confidence_matrix.png olarak kaydedilmiştir.



Şekil 4. Çok sınıflı ROC eğrileri (One-vs-Rest). Makro OVR AUROC = 0.9975.

gösterilmektedir. Her sınıf için [FPR, TPR] ikilisi, modelin softmax olasılıklarının tüm olası eşik değerlerindeki başarımını yansıtmaktadır. Makro OVR AUROC değeri 0.9975 olup, sınıflandırıcının tüm sınıfları mükemmel yakın ayırt edebildiğini göstermektedir. Sınıf bazında en yüksek AUROC değerleri Açık Tekerlekli / F1 (1.0000), Micro (0.9999) ve VAN (0.9995) sınıflarında elde edilmiştir. En düşük AUROC değerine sahip sınıf Hatchback (0.9917) olmasına rağmen, bu değer dahi mükemmel ayırım gücüne işaret etmektedir. Micro OVR AUROC (0.9984), sınıflar arası örnek sayısı farkına rağmen modelin ranking performansının tüm karar eşiklerinde tutarlı olduğunu doğrulamaktadır. Bu sonuçlar, Weighted CE kaybının azınlık sınıflarında yalnızca

sınıflandırma doğruluğunu değil, aynı zamanda olasılık sıralamasını da koruduğunu göstermektedir. ROC eğrileri ve AUROC değerleri, Dirichlet kalibrasyonu sonrası model olasılıkları kullanılarak 3170 iç test örneğinde hesaplanmış ve auroc_scores.json dosyasına kaydedilmiştir.

Karışıklık matrisi incelendiğinde diyagonal değerlerin yüksek olduğu, en sık hataların Hatchback-Sedan (Hatchback'lerin %5.6'sı Sedan olarak sınıflandırılmış) ve Pick Up-SUV (Pick Up'ların %3.7'si SUV olarak sınıflandırılmış) arasında gerçekleştiği görülmektedir. Bu hatalar fiziksel benzerlikten kaynaklanmaktadır: Hatchback ve Sedan arasındaki temel fark bagaj bölmesinin uzunluğudur ve önden çekilen görüntülerde bu ayırım zorlaşmaktadır. Benzer şekilde, Pick Up kasasının SUV'den ayrımı da yandan görünümde daha belirgindir.

En başarılı sınıflar sırasıyla F1 (0.9991), VAN (0.9856) ve Micro (0.9767) olmuştur. Bu sınıfların birbirinden ve diğer sınıflardan morfolojik olarak belirgin şekilde ayrışması (F1'in açık tekerlek yapısı, VAN'ın kutu formu, Micro'un kompakt boyutu) yüksek başarıyı açıklamaktadır. SUV sınıfında 670 örneğe karşılık 0.9504 F1 değeri, büyük örnek sayısına rağmen diğer büyük gövdeli araçlarla (Pick Up, Station Wagon) olan benzerlik nedeniyle nispet düşük kalmıştır.

C. Model Çıkarımı ve Web Arayüzü


Nihai model PyTorch safetensors (82.4 MB) ve ONNX Runtime (82.6 MB) formatlarına dışa aktarılmıştır. ONNX dönüşümü sırasında modelin hesaplama grafiği optimize edilerek operatörler birleştirilmiş, böylece çıkarım süresi PyTorch'a kıyasla %12 iyileştirilmiştir. Her iki format da proje teslim şartı olan 95 MB sınırının altındadır; bu nedenle herhangi bir niceleme (quantization) işlemine gerek kalmamıştır.

Gradio tabanlı web arayüzü, görsel yükleme (sürükle-bırak dosya veya manuel seçim), anlık önizleme, tahmin sonucu ve Dirichlet kalibreli olasılık dağılımlarını çubuk grafik (bar chart) olarak göstermektedir. Kullanıcı, modelin en yüksek olasılık atadığı sınıfı, ikinci en yüksek olasılığı ve tüm sınıfların güven dağılımını tek ekranda görebilmektedir. Arayüz, tek seferde birden fazla görsel yüklemeye ve toplu tahmine de olanak tanımaktadır.

M2 Pro üzerinde ONNX Runtime ile ortalama 39.6 ms gecikme süresi (tek örneklik: 44.2 ms) ölçülmüştür. Gerçek zamanlı kullanım için kabul edilebilir bu değer, modelin potansiyel bir REST API servisi olarak da kullanılabileceğini göstermektedir.

V. SINIRLAMALAR VE TARTIŞMA

Mevcut sistemin bazı sınırlılıkları bulunmaktadır: (1) Veri seti yalnızca açık kaynaklardan toplanmış olup farklı hava/ışık koşullarını, mevsimleri ve coğrafi bölgeleri kapsayan bir dış test seti ile genelleme henüz doğrulanmamıştır. Modelin gerçek dünya performansı, bu tür çeşitlilik içeren bir dış test ile ölçülmelidir. (2) Hatchback ve Sedan sınıfları arasındaki ayırım, yapısal benzerlik (kısa bagaj, eğimli arka cam) nedeniyle en düşük F1 skoruna (0.8731) sahiptir. Bu iki sınıfın ayrımı için yan/arka profil odaklı ek özneteliklere ihtiyaç duyulmaktadır. (3) DINOv3'ün daha büyük varyantları (ViT-B/16, ViT-L/14)



Şekil 5. AutoLens AI web arayüzü kullanıcı ekranı.

daha yüksek başarımla potansiyeline sahip olmasına rağmen, 95 MB model boyut sınırı nedeniyle denenememiştir. Hali hazırda ViT-S/16 bile 82.4 MB ile bu sınıra oldukça yakındır. (4) Eğitim yalnızca M2 Pro (MPS) donanımında gerçekleştirilmiş, CUDA/TPU gibi alternatif platformlarda test edilmemiştir. Farklı donanımlarda eğitim dinamiği ve sayısal hassasiyet (BF16 vs FP32) değişebilir. (5) Focal Loss ablasyonunda γ değeri sabit ($\gamma = 2.0$) tutulmuş, farklı γ değerleri taranmamıştır. Daha düşük γ değerleri Weighted CE'ye yakınsayabilir. (6) Kalibrasyon yöntemleri yalnızca aynı dağılımdaki doğrulama setinde optimize edilmiş olup, dağılım dışı (out-of-distribution) verilerdeki kalibrasyon performansı ölçülmemiştir. (7) Dirichlet kalibrasyon modeli (8×8 ağırlık matrisi + 8 bias) yalnızca 72 parametre içermesine rağmen, her yeni veri seti için yeniden eğitilmesi gerekmektedir. Temperature Scaling'in tek parametreliliğine kıyasla bu bir operasyonel dezavantajdır.

Bu sınırlamalara rağmen, sistematik karşılaştırma protokolümüz sayesinde elde edilen bulguların genellenebilir olduğu düşünülmektedir. Özellikle Dirichlet kalibrasyonunun ağırlıklandırılmış kayıp fonksiyonlarından kaynaklanan olasılık bozulmasını düzeltmedeki başarısı, dengesiz veri setleriyle çalışan diğer sınıflandırma problemlerine de ışık tutmaktadır.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada 8 farklı araba gövde tipini sınıflandıran AutoLens AI sistemi sunulmuştur. Dört farklı mimari (ResNet18, EfficientNet-B2, MobileNetV4, DINOv3 ViT-S/16) aynı veri bölütlemesi ve değerlendirme protokolü altında sistematik olarak karşılaştırılmış, DINOv3'ün öz-denetimli ön eğitim sayesinde CNN tabanlı modellere Makro F1'de +0.0205 ila +0.0677 puan üstünlük sağladığı deneysel olarak gösterilmiştir.

Ablasyon çalışmalarında iki önemli bulgu elde edilmiştir. Birincisi, Weighted Cross-Entropy Loss ile Focal Loss karşılaştırmasında, Weighted CE'nin özellikle azınlık sınıflarında (Micro +0.0465, Station Wagon +0.0650 F1) belirgin iyileşme

sağladığı, genel Makro F1'de +0.0205 puan üstünlük kurduğu kanıtlanmıştır. İkincisi, güvenli veri artırımı politikası ve EMA'nın Makro F1'de +0.0320 puan ek iyileşme sağladığı doğrulanmıştır.

Olasılık kalibrasyonu çalışmaları kapsamında üç yöntem karşılaştırılmıştır: Temperature Scaling, Vector Scaling ve Dirichlet (ODIR) kalibrasyonu. Dirichlet yöntemi, Val NLL (0.1371), ECE (%0.97) ve Test F1 (0.9537) metriklerinde rakiplerini geride bırakmış, modelin aşırı güven sorununu %90 oranında azaltmıştır. Dört farklı model üzerinde yapılan kalibrasyon analizi, ağırlıklandırma gibi post-hoc düzenlemelerin kalibrasyon ihtiyacını artırdığını ancak Dirichlet yönteminin bu durumda en etkili çözüm olduğunu göstermiştir. Ayrıca λ taraması (Tablo X), Dirichlet kalibrasyonunun düzenleme parametresine duyarlı olduğunu ve $\lambda = 0.001$ 'in en uygun değer olduğunu ortaya koymuştur.

Nihai model (DINOv3 + Safe Aug + Weighted CE + Dirichlet) %95.84 doğruluk, 0.9507 Makro F1 ve 82.6 MB ONNX boyut değerleriyle tüm proje gereksinimlerini karşılamış, Gradio tabanlı web arayüzü ile canlı demo olarak sunulmuştur. Modelin M2 Pro üzerinde ölçülen 39.6 ms gecikme süresi, gerçek zamanlı sınıflandırma senaryoları için uygun olduğunu göstermektedir.

Bu çalışmanın en önemli katkılarından biri, dengesiz veri setlerinde Weighted CE ve Dirichlet kalibrasyonu kombinasyonunun sistematik olarak değerlendirilmesidir. Elde edilen bulgular –özellikle ağırlıklandırmanın olasılık dağılımını bozduğu ancak Dirichlet kalibrasyonunun bu bozulmayı düzelttiği yönündeki sonuç– yalnızca araba gövde tipi sınıflandırması için değil, dengesiz sınıf dağılımına sahip diğer görüntü sınıflandırma problemleri için de yol göstericidir.

Gelecek çalışmalarda Hatchback-Sedan ayrımını güçlendirmek için arka profil ve bagaj yapısına odaklanan ikincil bir sınıflandırıcı geliştirilebilir. Ayrıca modelin genelleme kapasitesi farklı coğrafi bölgelerden toplanmış dış test setleri ile sınanabilir. Model boyutunun izin verdiği ölçüde DINOv3'ün daha büyük varyantlarının (Base) performansı değerlendirilebilir. Son olarak, Focal Loss için hiperparametre taraması (γ değerleri) yapılarak daha adil bir karşılaştırma sağlanabilir ve Dirichlet kalibrasyonunun diğer modellerdeki etkisi daha geniş kapsamlı analiz edilebilir.

KAYNAKLAR

- [1] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [2] M. Tan and Q. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *International conference on machine learning*. PMLR, 2019, pp. 6105–6114.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
- [4] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, "Emerging properties in self-supervised vision transformers," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 9650–9660.
- [5] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Soyer, V. Yin *et al.*, "Dinov2: Learning robust visual features without supervision," *arXiv preprint arXiv:2304.07193*, 2023.

- [6] M. Kull, M. Perello Nieto, M. Kängsepp, T. Silva Filho, H. Song, and P. Flach, "Beyond temperature scaling: Obtaining well-calibrated multi-class probabilities with dirichlet calibration," *Advances in neural information processing systems*, vol. 32, 2019.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel *et al.*, "Scikit-learn: Machine learning in python," <https://scikit-learn.org>, 2011.