

AutoLens AI: Görüntü İşleme ve Derin Öğrenme ile Araba Gövde Tipi Sınıflandırma

*Kocaeli Üniversitesi Yazılım Laboratuvarı-II Proje 3

Enes Demir
Bilgisayar Mühendisliği
Kocaeli Üniversitesi
Kocaeli, Türkiye
230202066@kocaeli.edu.tr

Özet—Sekiz farklı araba gövde tipini sınıflandırmak için AutoLens AI adlı derin öğrenme sistemi geliştirilmiştir. Sınıflar arası ciddi veri dengesizliği (Micro 22, SUV 670 örnek) Weighted Cross-Entropy Loss ile aşılmış; CNN ve Vision Transformer mimarileri sistematik olarak karşılaştırılmıştır. En yüksek başarımlı, öz-denetimli öğrenme ile ön eğitilmiş DINOv3 ViT-S/16 modelinin güvenli veri artırımı ve Dirichlet kalibrasyonu ile birleştirilmesiyle elde edilmiştir. Nihai model, 3170 örnekle iç test setinde %95.84 doğruluk, 0.9507 Makro F1 ve %0.97 Expected Calibration Error (ECE) değerlerine ulaşmıştır. Model 95 MB sınırının altında (82.6 MB ONNX) optimize edilmiş ve Gradio tabanlı web arayüzü ile sunulmuştur.

Index Terms—Derin Öğrenme, Görüntü Sınıflandırma, Vision Transformer, DINOv3, Kalibrasyon, Araba Gövde Tipi.

I. GİRİŞ

Günümüzde otonom sistemler, trafik yönetimi ve güvenlik alanlarında araçların fiziksel özelliklerinin doğru ve hızlı tespiti büyük önem taşımaktadır. Bu çalışma kapsamında, sekiz farklı araç gövde tipini (SUV, VAN, Station Wagon, Micro, Açık Tekerlekli/F1, Sedan, Hatchback, Pick-up) sınıflandıran bir derin öğrenme modeli geliştirilmiştir.

Katkılarımız dört ana başlıkta özetlenebilir:

- 1) **Sistematik model karşılaştırması:** Dört farklı mimari (ResNet18, EfficientNet-B2, MobileNetV4, DINOv3 ViT-S/16) aynı veri bölütlemesi ve değerlendirme protokolü altında karşılaştırılmış, LoRA ve tam ince ayar varyantları ayrı ayrı test edilmiştir.
- 2) **Veri dengesizliği stratejisi:** Focal Loss ve Weighted Cross-Entropy Loss, DINOv3 üzerinde ablasyon çalışmalarıyla karşılaştırılmış; Weighted Loss'un Makro F1'de +0.0205 puan üstün olduğu gösterilmiştir.
- 3) **Güvenli veri artırımı (safe augmentation):** Aracın silüetini koruyan, agresif dönüşümlerden kaçınan bir artırım politikası uygulanmış ve genelleme başarısına katkısı deneysel olarak doğrulanmıştır.
- 4) **Probability kalibrasyonu:** Dirichlet kalibrasyonu ile ECE %9.84'ten %0.97'ye düşürülmüş, modelin aşırı güven (overconfidence) sorunu giderilmiştir.

Veri seti açık kaynaklardan toplanmış, sınıflar arası dengesizlik sınıf ağırlıklı hata fonksiyonları ile ele alınmıştır. Proje teslim gereksinimleri doğrultusunda model 95 MB altında

ONNX formatında paketlenmiş ve canlı demo web arayüzü ile sunulmuştur.

II. İLGİLİ ÇALIŞMALAR

Araç sınıflandırma sistemleri üzerine literatürde birçok çalışma bulunmaktadır. Geleneksel yöntemler HOG (Histogram of Oriented Gradients) gibi el yapımı özniteliklere dayanırken, son yıllarda CNN'ler bu alanda baskın hale gelmiştir. ResNet ve EfficientNet gibi mimariler görüntü sınıflandırmada yüksek başarı elde etmiştir [1], [2].

Transformer mimarisinin görüntü işlemeye uyarlanmasıyla ortaya çıkan Vision Transformer (ViT) modelleri, uzun mesafeli bağımlılıkları yakalama kapasiteleri sayesinde CNN'lere güçlü bir alternatif oluşturmuştur [3]. Öz-denetimli öğrenme yaklaşımını kullanan DINO serisi [4], [5], etiketli veriye ihtiyaç duymadan güçlü görsel temsiller öğrenmektedir. Olasılık kalibrasyonunda ise Dirichlet kalibrasyonu, çok sınıflı problemlerde Temperature Scaling'e kıyasla daha esnek bir düzeltme sunmaktadır [6].

III. SİSTEM MIMARISI VE METODOLOJİ

A. Veri Seti ve Ön İşleme

Sınıflandırma için SUV, VAN, Station Wagon, Micro, Açık Tekerlekli (F1), Sedan, Hatchback ve Pick Up olmak üzere 8 sınıf belirlenmiştir. Toplam 31,612 görüntü (eğitim: 25,285, doğrulama: 3,157, iç test: 3,170) açık kaynaklardan toplanmıştır. Sınıf dağılımları doğal olarak dengesizdir (SUV 670, Micro 22 örnek). Görüntüler 256×256 boyutunda yeniden boyutlandırılıp merkez kırpma uygulanmıştır. Güvenli veri artırımı politikası ile aracın silüetini bozmayacak hafif perspektif dönüşümleri, renk/aydınlık ayarlamaları ve yatay çevirme uygulanmış; Hatchback-Sedan ayrımını bozacak agresif kırpma veya döndürmeden kaçınılmıştır.

B. Model Mimarisi ve Karşılaştırması

İlk aşamada üç CNN mimarisi test edilmiştir: ResNet18 (11M parametre), EfficientNet-B2 (9M) ve MobileNetV4-Conv-M (9M). Ardından Vision Transformer tabanlı DINOv3 ViT-S/16 (21.6M parametre) değerlendirilmiştir. DINOv3'ün

Tablo I
TÜM MODEL ADAYLARININ İÇ TEST SETİ KARŞILAŞTIRMASI (3170 ÖRNEK)

Model	Doğruluk ↑	Macro F1 ↑	Parametre	Boyut
DINOv3 (Tam)	0.9438	0.9187	21.6M	82.4 MB
EfficientNet-B2	0.9202	0.8982	9.0M	29.7 MB
ResNet18	0.8968	0.8590	11.2M	42.7 MB
MobileNetV4	0.8905	0.8510	9.0M	32.5 MB
DINOv3 (LoRA)	0.7820	0.6316	21.6M	82.4 MB

LoRA (r=8, alpha=16) ve tam ince ayar varyantları ayrı ayrı test edilmiştir.

Tablo I görüldüğü üzere, DINOv3 tam ince ayar varyantı tüm metriklerde CNN tabanlı modelleri geride bırakmıştır. LoRA varyantı ise düşük başarımlı (0.6316 F1) nedeniyle elenmiştir. DINOv3'ün öz-denetimli ön eğitimi sayesinde sınırlı veri ile yüksek genelleme sağladığı gözlemlenmiştir.

C. Ablasyon Çalışmaları

1) *Kayıp Fonksiyonu: Focal vs Weighted CE*: Sınıf dengesizliğini ele almak için iki kayıp fonksiyonu DINOv3 üzerinde karşılaştırılmıştır. Weighted Cross-Entropy, sınıf frekanslarının tersiyle ağırlıklandırma yaparken (maksimum ağırlık 5.0 ile sınırlı), Focal Loss ($\gamma = 2.0$) zor örnekler odaklanmaktadır.

Tablo II
KAYIP FONKSİYONU ABLASYONU (DINOv3 + SAFE AUG + EMA)

Metric	Weighted CE	Focal Loss	Fark
Accuracy ↑	0.9584	0.9505	+0.0079
Macro F1 ↑	0.9507	0.9302	+0.0205
Weighted F1 ↑	0.9584	0.9502	+0.0082
Micro sınıfı F1	0.9767	0.9302	+0.0465
Hatchback F1	0.8731	0.8628	+0.0103
Station Wagon F1	0.9302	0.8652	+0.0650

Weighted CE, özellikle azınlık sınıflarında (Micro +0.0465 F1, Station Wagon +0.0650 F1) belirgin iyileşme sağlamış ve toplamda +0.0205 Makro F1 üstünlük elde etmiştir.

2) *Veri Artırımı Etkisi*: Veri artırımının katkısını ölçmek için augmentasyonsuz DINOv3 (Baseline) ile safe augmentation kullanılan versiyon karşılaştırılmıştır:

Tablo III
VERİ ARTIRIMI ABLASYONU (DINOv3 + WEIGHTED CE)

Konfigürasyon	Accuracy	Macro F1	Weighted F1
Augmentasyonsuz (Baseline)	0.9438	0.9187	0.9442
Safe Aug + EMA	0.9584	0.9507	0.9584

Safe augmentation ve EMA eklenmesi Makro F1'de +0.0320 puanlık bir artış sağlamıştır.

D. Eğitim Hiperparametreleri

Nihai model, Tablo IV hiperparametreler ile eğitilmiştir. AdamW optimizörü, Erken Durdurma (patience=12, monitor=val/f1_macro) ve BF16 karma hassasiyet kullanılmıştır.

Model 42 epoch sonunda eğitilmiş, en iyi ağırlıklar 29. epoch'ta kaydedilmiştir.

Tablo IV
NİHAİ MODEL EĞİTİM HIPERPARAMETRELERİ

Parametre	Değer
Model	DINOv3 ViT-S/16
Giriş boyutu	256×256
Batch size	128
Optimizör	AdamW
Öğrenme oranı	0.0001
Weight decay	0.0001
Label smoothing	0.05
EMA decay	0.999
Drop path rate	0.1
Gradient clip	1.0
Karma hassasiyet	BF16
Erken durdurma	patience=12
Loss fonksiyonu	Weighted CE (max=5.0)
En iyi epoch	29 / 42

E. Olasılık Kalibrasyonu

Üç kalibrasyon yöntemi karşılaştırılmıştır: Temperature Scaling, Vector Scaling ve Dirichlet (ODIR) kalibrasyonu. Dirichlet yöntemi, her sınıf için ayrı bir beta dağılımı parametrelendirerek çok sınıflı olasılıkları düzeltmektedir.

Tablo V
KALIBRASYON YÖNTEMLERİ KARŞILAŞTIRMASI (DINOv3 WEIGHTED)

Yöntem	Val NLL ↓	ECE ↓	Test F1
Kalibrasyonsuz	0.2585	0.1033	–
Temperature Scaling	0.2045	0.0211	0.9496
Vector Scaling	0.1706	0.0232	0.9450
Dirichlet (ODIR)	0.1371	0.0096	0.9537

Dirichlet kalibrasyonu ECE'yi %10.33'ten %0.96'ya düşürerek en başarılı yöntem olmuştur. Bu iyileşme, modelin aşırı güven (overconfidence) problemini büyük ölçüde gidermiştir.

IV. DEĞERLENDİRME VE SONUÇLAR

A. Performans Metrikleri

Nihai model (DINOv3 + Safe Aug + Weighted CE + Dirichlet) 3170 örnekli iç test setinde %95.84 doğruluk, 0.9507 Makro F1 ve 0.9584 Weighted F1 değerlerine ulaşmıştır.


Tablo VI
DINOv3 SINIF BAZLI PERFORMANS METRİKLERİ (İÇ TEST)

Sınıf	Precision	Recall	F1	Örnek
SUV	0.9576	0.9433	0.9504	670
VAN	0.9933	0.9780	0.9856	455
St. Wagon	0.9524	0.9091	0.9302	66
Micro	1.0000	0.9545	0.9767	22
F1	1.0000	0.9983	0.9991	586
Sedan	0.9496	0.9689	0.9591	836
Hatchback	0.8667	0.8797	0.8731	266
Pick Up	0.9296	0.9331	0.9314	269


En yüksek başarımlı F1 araçları sınıfında (0.9991 F1), en düşük başarımlı ise Hatchback sınıfında (0.8731 F1) elde edilmiştir. Micro sınıfında yalnızca 22 örnek olmasına rağmen 0.9767 F1 değeri, ağırlıklandırma stratejisinin başarısını kanıtlamaktadır.

B. Eğitim Süreci ve Karışıklık Matrisi


Eğitim ve doğrulama kayıpları birbirine yakın seyretmiş, aşırı öğrenme belirtisi gözlemlenmemiştir. Şekil 1 ve 2 eğitim sürecini göstermektedir.



Şekil 1. Epochlara göre eğitim ve doğrulama kaybı (Loss) grafiği.



Şekil 2. Epochlara göre eğitim ve doğrulama doğruluğu (Accuracy) grafiği.



Şekil 3. Normalize edilmiş karışıklık matrisi (8x8).


Karışıklık matrisi incelendiğinde diyagonal değerlerin yüksek olduğu, en sık hataların Hatchback-Sedan ve Pick Up-SUV arasında gerçekleştiği görülmektedir.

C. Web Arayüzü

Model ONNX (82.6 MB) ve Safetensors (82.4 MB) formatlarına dışa aktarılmış, Gradio tabanlı web arayüzü ile entegre edilmiştir. Arayüz görsel yükleme (sürükle-bırak), anlık önizleme, tahmin ve Dirichlet kalibreli olasılık dağılımlarını çubuk grafik olarak sunmaktadır. M2 Pro üzerinde 15-40 ms gecikme süresi ölçülmüştür.

VI. SINIRLAMALAR

Mevcut sistemin bazı sınırlılıkları bulunmaktadır: (1) Veri seti yalnızca açık kaynaklardan toplanmış olup farklı hava/ışık



Şekil 4. AutoLens AI web arayüzü kullanıcı ekranı.

koşullarını kapsayan dış test seti ile genelleme henüz doğrulanmamıştır. (2) Hatchback ve Sedan sınıfları arasındaki ayırım, yapısal benzerlik nedeniyle en düşük F1 skoruna (0.8731) sahiptir. (3) Model 82.4 MB ile boyut sınırının altında olmasına rağmen, daha büyük ViT varyantları (Base/Large) aynı sınır nedeniyle denenememiştir. (4) Eğitim yalnızca M2 Pro (MPS) donanımında gerçekleştirilmiş, CUDA/TPU gibi alternatif platformlarda test edilmemiştir.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada 8 farklı araba gövde tipini sınıflandıran AutoLens AI sistemi sunulmuştur. Dört farklı mimari sistematik olarak karşılaştırılmış, DINOv3'ün CNN tabanlı modellere üstünlüğü deneysel olarak gösterilmiştir. Weighted CE Loss ile azınlık sınıflarında +0.065 F1 iyileşme sağlanmış, Dirichlet kalibrasyonu ile ECE %10.33'ten %0.96'ya düşürülmüştür. Nihai model %95.84 doğruluk, 0.9507 Makro F1 ve 82.4 MB boyut değerleriyle tüm proje gereksinimlerini karşılamıştır.

Gelecek çalışmalarda Hatchback-Sedan ayırımını güçlendirmek için arka profil odaklı ikincil modeller geliştirilebilir. Ayrıca modelin genellemesi farklı veri dağılımlarından dış test setleri ile sınanabilir.

KAYNAKLAR

- [1] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [2] M. Tan and Q. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *International conference on machine learning*. PMLR, 2019, pp. 6105–6114.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
- [4] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, "Emerging properties in self-supervised vision transformers," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 9650–9660.
- [5] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Soyer, V. Yin *et al.*, "Dinov2: Learning robust visual features without supervision," *arXiv preprint arXiv:2304.07193*, 2023.
- [6] M. Kull, M. Perello Nieto, M. Kängsepp, T. Silva Filho, H. Song, and P. Flach, "Beyond temperature scaling: Obtaining well-calibrated multi-class probabilities with dirichlet calibration," *Advances in neural information processing systems*, vol. 32, 2019.